

机器学习上机实验01：数据集构建与近邻分类初探

一、实验题目

从互联网图像爬取到二分类模型评估：全流程实践

二、实验目标

- 数据获取能力**：学习使用 Python 工具从搜索引擎抓取特定类别图片的方法。
- 数据理解能力**：理解数字图像在计算机中的底层表示（像素阵列、RGB 通道、张量维度）。
- 预处理工程化**：学习统一图像规格、标注标签以及处理异常受损数据的技巧，掌握数据集的科学拆分原则。
- 训练评估基础**：理解实现最近邻模型、混淆矩阵（TP, FP, FN, TN）。
- 误差分析意识**：通过观察分类错误的样本，分析潜在因素对“像素级比较”算法的影响。

三、实验环节与任务清单

1. 原始数据采集 (Data Collection)

- 任务**：选定两个互斥的类别（如：猫 vs 狗、建筑 vs 森林），利用爬虫脚本各下载50 张原始图片。

2. 数据探索与清洗 (Data Exploring & Cleaning)

- 任务 A**：查看下载目录，手动剔除与主题无关或完全损毁的图片（缺少图片重新下载补充）。
- 任务 B**：在代码中打印一张图片的 `Shape`，观察图像在计算机中的存储状态，记录其高度、宽度和通道数。

3. 图像预处理 (Pre-processing)

- 任务 A**：将所有图片进行等比例缩放（统一为64x64x3大小），确保输入特征维度一致。
- 任务 B**：为每张图片打上标签，形成数据集。

4. 实验数据集拆分 (Dataset Splitting)

- 任务**：按照 70% 训练集 / 15% 验证集 / 15% 测试集 的比例拆分数据。

5. 建立最近邻模型 (1-NN Classification)

- **任务：**计算验证集图片与训练集样本之间的“距离”，实现初步自动分类，学习使用sklearn包实现，并尝试自行编写代码实现算法。

6. 结果统计与归因分析 (Evaluation)

- **任务 A：**输出实验的混淆矩阵，统计True Positive, False Positive, False Negative, True Negative等关键指标，自行编写代码实现。
 - **任务 B：**分析图片分类错误的潜在原因。
-

四、作业要求

- **数据：**保留数据集，作为后续实验备用。
- **代码：**整理出代码文件，规范添加注释。
- **报告：**依据本实验内容，形成实验报告。