

机器学习上机实验02：聚类与联合概率分布

一、实验题目

从概率分布建模到图像特征聚类：K-Means 算法全流程实战

二、实验目标

- 概率统计直观化**：通过调整协方差矩阵，理解多维高斯分布的几何特性及其对数据分布的影响。
- 算法底层实现能力**：掌握 K-Means (Lloyd's Algorithm) 的迭代逻辑。
- 色彩空间处理能力**：学习将聚类算法应用于图像压缩与色彩量化。
- 高维特征聚类与分析**：探索非监督方法K-Means (Lloyd's Algorithm) 在图像二分类任务中的表现与局限性。

三、实验环节与任务清单

1. 概率分布生成与协方差矩阵观察 (Probability & Covariance)

- 任务 A**：使用 `np.random.multivariate_normal` 生成二维高斯分布数据（每组 200 个点），重点观察并对比以下4种协方差矩阵模式下的数据散点图（可保持均值相同），解释现象背后原因。

类别	数学条件	协方差矩阵示例
各向同性 (Isotropic)	$\Sigma = \sigma^2 I$	$\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$
非相关各向异性 (Uncorrelated Anisotropic)	对角矩阵但方差不同	$\begin{bmatrix} 5 & 0 \\ 0 & 1 \end{bmatrix}$
相关各向异性 (Correlated Anisotropic)	存在非零协方差	$\begin{bmatrix} 1 & 0.8 \\ 0.8 & 1 \end{bmatrix}$
相关各向异性 (Correlated Anisotropic)	非零协方差且方差不同	$\begin{bmatrix} 5 & 0.8 \\ 0.8 & 1 \end{bmatrix}$

2. 手动实现 K-Means算法 (Algorithm Implementation)

- **任务 A:** 使用 `np.random.multivariate_normal` 生成4组二维高斯分布数据（均值和协方差按如下给定数值设定，每组 200 个点），手动编写 K-Means 核心循环对此800个点进行聚类。设置K=4，对初始聚类中心进行随机初始化，迭代更新分配与中心过程，直至收敛。可视化最终聚类结果。

```
means = [ [0,0], [3,1], [1,4], [4,4] ]
```

```
cov = [[1,0],[0,1]]
```

- **任务B:** 设置K=8，观察对比两个聚类结果。
- **任务C:** 尝试不同的初始聚类中心初始化，观察对比两个聚类结果。

3. 像素级色彩量化实战 (Pixel-level K-Means)

- **任务 A:** 读取文件包内的图片“实验02-菜市场.jpg”，将其维度从 $(H, W, 3)$ 转换为 $(N, 3)$ 的像素向量矩阵。
- **任务 B:** 修改上面的K-Means算法，设置 $K=7$ ，对图像颜色进行聚类。
- **任务 C:** 在三维坐标系内，可视化像素聚类结果。
- **任务D:** 利用聚类中心颜色重构图像，观察并对比原图与色彩量化后的视觉差异。

4. 图像级特征聚类与评估 (Image Feature Clustering)

- **任务 A:** 修改上面的K-Means算法，将上节课采集的数据集（包含：100张图像，2类，每类各50张，每张图处理后大小为 $64 \times 64 \times 3$ ）进行 $K=2$ 的聚类。
- **任务 B:** 统计聚类结果与原始标签的一致性，通过观察分类错误的样本，分析原因。
- **任务C:** 可视化出2个聚类中心（Reshape为 $64 \times 64 \times 3$ ），观察其区别。

四、作业要求

- **数据:** 保留数据集，作为后续实验备用。
- **代码:** 整理出代码文件，规范添加注释。
- **报告:** 依据本实验内容，形成实验报告。