

机器学习上机实验03：概率密度估计与高斯混合模型

一、实验题目

从极大似然估计到隐变量建模：高斯混合模型（GMM）与 EM 算法底层实战

二、实验目标

- 概率建模深度理解**：通过手动构造异构高斯分布，理解协方差矩阵对数据几何形态（各向异性）的控制。
- 底层算法实现能力**：利用 **Numpy** 矩阵运算实现 EM 算法的全流程。
- 隐变量逻辑推导**：掌握在标签丢失状态下，如何通过“期望-极大化”循环逼近真实分布。

三、实验环节与任务清单

1. 异构数据生成与初步观察 (Data Generation)

任务 A：使用 `np.random.multivariate_normal` 生成两组二维高斯分布数据（簇 A: 200点, 簇 B: 400点），随机种子设为 `np.random.seed(42)`。

• **均值设定**： $\mu_1 = [1, 1], \mu_2 = [4, 4]$

• **协方差设定**：

$\Sigma_1 = \begin{bmatrix} 1.0 & 0.8 \\ 0.8 & 1.0 \end{bmatrix}$ (强正相关), $\Sigma_2 = \begin{bmatrix} 1.2 & -0.6 \\ -0.6 & 0.8 \end{bmatrix}$ (负相关)

• **可视化**：绘制散点图。观察当维度间存在相关性时，数据是如何沿对角线“拉伸”的。

2. （非混合高斯分布，无隐变量）-> 极大似然参数估计 (MLE)

任务 A：一元 MLE 验证。取簇 A 的第一列数据 x (200个数值)，采用MLE结论估算其均值与方差。

• **公式**： $\hat{\mu} = \frac{1}{N} \sum_{i=1}^N x_i, \quad \hat{\sigma}^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{\mu})^2$

拓展：二元 MLE推导思路与一元MLE相同，MLE对参数估计如下，其中 C_k 代表 第 k个簇 (Cluster) 的样本集合，感兴趣同学可据此计算。

• **均值公式**： $\hat{\mu}_k = \frac{1}{N_k} \sum_{x \in C_k} x$

- 协方差公式： $\hat{\Sigma}_k = \frac{1}{N_k} \sum_{x \in \mathcal{C}_k} (x - \hat{\mu}_k)(x - \hat{\mu}_k)^T$

3. (混合高斯分布, 含隐变量) -> EM 算法 (EM Algorithm)

引出：隐变量 z 未知，直接对 $\ln P(X|\theta)$ 进行极大似然参数估计，参数与标签耦合严重，难以计算。-> EM算法：将隐变量 z 视为“已知”标签（本质是后验概率构造的软标签），采用最大期望对数似然计算参数 θ （即权重 π_k 、均值 μ_k 和协方差 Σ_k ）；根据计算出的新参数，使用贝叶斯法则更新隐变量后验概率，如此迭代优化，直到收敛。

任务 A：基于 K-Means 的参数初始化。

- 利用 K-Means 聚类结果，计算各高斯分量初始权重 $\pi_k^{(0)}$ 、均值 $\mu_k^{(0)}$ 和协方差 $\Sigma_k^{(0)}$ 。

任务 B：E-Step（计算响应度）。

- **任务：**计算每个样本 x_n 属于第 k 个高斯分量的后验概率（软标签）。
- **公式：**

$$\gamma(z_{nk}) = \frac{\pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(x_n | \mu_j, \Sigma_j)}$$

任务 C：M-Step（参数更新）。

- **任务：**利用 $\gamma(z_{nk})$ 对参数进行加权更新。
- **均值更新：**
- $$\mu_k^{new} = \frac{\sum_{n=1}^N \gamma(z_{nk}) x_n}{\sum_{n=1}^N \gamma(z_{nk})}$$
- **协方差更新：**
- $$\Sigma_k^{new} = \frac{\sum_{n=1}^N \gamma(z_{nk}) (x_n - \mu_k^{new})(x_n - \mu_k^{new})^T}{\sum_{n=1}^N \gamma(z_{nk})}$$
- **权重更新：**
$$\pi_k^{new} = \frac{\sum_{n=1}^N \gamma(z_{nk})}{N}$$

任务 D：收敛判定。

- 计算对数似然函数值

$$\ln P(X|\theta) = \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k) \right)$$

- **收敛判定：** $\Delta L = \ln P(X|\theta)_{iter} - \ln P(X|\theta)_{iter-1}$ ，当 $\Delta L < tol$ ，认为算法已收敛，通常设定 $tol = 10^{-6}$ 。
- 判定为收敛后，使用最终参数写出随机变量 X 的 GMM 概率密度公式。

4. 算法对比与评估 (Evaluation)

可视化对比：在同一张图中对比 K-Means 的直线划分边界与 GMM 的概率等值线。

四、作业要求

- **数据：**保留数据集，作为后续实验备用。
- **代码：**整理出代码文件，规范添加注释。
- **报告：**依据本实验内容，形成实验报告。
- **提交作业：**将之前上机课的数据集、代码、报告（自上次提交报告到本次，中间所有上机报告内容整合为一份），打包后提交。提交截止日期为4月10日23点59分，提交方式后续在QQ群内通知。