机器学习上机实验04：线性回归-1

一、 实验题目

从正规方程到基函数扩展：线性回归解析解实战

二、 实验目标

- **代数运算底层实现**：掌握线性回归正规方程（Normal Equation）的矩阵运算逻辑。
- **矩阵性质直观理解**：通过实验验证设计矩阵的满秩条件及其对模型可解性的影响。
- **几何投影视角构建**：理解最小二乘法在向量空间中的正交投影本质。
- **模型复杂度探索**：学习多项式基函数扩展，通过观察过拟合现象理解模型泛化能力与阶数 M 的关系。

三、 实验环节与任务清单

> **注**：随机种子统一使用 `np.random.seed(42)`

1. 线性气温预测模型的解析解实现 (Linear Regression & Normal Equation)

> 本实验旨在通过合成的“海拔-纬度-气温”数据集，验证线性回归的正规方程（Normal Equation）解法。你需要构建一个设计矩阵 $\mathbf{X}$，并证明其满足满秩条件，从而求解出最优参数 $\mathbf{w}$。

- **步骤 A：构建合成数据集**

  利用 `numpy` 生成 $N = 100$ 个样本。特征向量应包含：

  - Feature 1 (海拔 x_1): 在 $[0, 2000]$ 范围内均匀分布的随机数。
  - Feature 2 (纬度 x_2): 在 $[0, 90]$ 范围内均匀分布的随机数。
  - 偏置项: 必须在设计矩阵中包含一列全为 1 的向量。
  - 数学表达：构造设计矩阵 $\mathbf{X} \in \mathbb{R}^{100\times 3}$，其形式为：

$$\mathbf{X} = \begin{bmatrix} 1 & x_{1,1} & x_{2,1} \\ 1 & x_{1,2} & x_{2,2} \\ \vdots & \vdots & \vdots \\ 1 & x_{1,100} & x_{2,100} \end{bmatrix}$$

- **步骤 B：生成观测标签 $\mathbf{y}$**

  设定真实的权重参数 $\mathbf{w}_{true} = [30.0, -0.006, -0.2]^T$，并加入高斯噪声 $\epsilon \sim \mathcal{N}(0, 1)$。

  计算： $\mathbf{y} = \mathbf{X}\mathbf{w}_{true} + \epsilon$。

- **步骤 C：满秩性验证**

在求解前，必须验证 $\mathbf{X}^T\mathbf{X}$ 是否可逆。
  - 任务：使用 `np.linalg.matrix_rank` 计算 $\mathbf{X}$ 的秩。
  - 思考：若 N=100, D=3，矩阵满秩的充要条件是什么？如果采样点完全相同，会发生什么？
- **步骤 D：求解与评估**
  - **手动实现正规方程**：利用 `np.linalg.inv` 求解 $\hat{\mathbf{w}} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$ 。
  - **对比**：打印 $\hat{\mathbf{w}}$ 与 $\mathbf{w}_{true}$ ，计算两者之间的欧几里得距离，并可视化数据与预测的超平面。
- **步骤E：几何解释**

  计算残差向量 $\mathbf{r} = \mathbf{y} - \mathbf{X}\hat{\mathbf{w}}$ ，并计算 $\mathbf{r}$ 与 $\mathbf{X}$ 的每一列的点积，说明预测向量 $\mathbf{X}\hat{\mathbf{w}}$ 是真值向量 $\mathbf{y}$ 在设计矩阵 $\mathbf{X}$ 张成空间（列空间）上的正交投影。
- **思考：**如果我们的采样点特征间满足 $x_1 + x_2 = 100$ 这样的线性关系，正规方程还能解吗？

2. 多项式基底与模型复杂度 (Polynomial Basis & Model Complexity)

> 在现实世界中，特征与标签之间的关系往往是非线性的。本实验通过手动构造多项式基函数的设计矩阵 $\mathbf{\Phi}$ ，利用线性回归的解析解来拟合一个正弦信号，并探索模型阶数 M 对泛化能力的影响。

- **步骤 A：合成数据集生成**
  - 样本量：生成 N=15 个采样点（小样本量更容易观察到过拟合现象）。
  - 输入 x ：在 [0, 1] 范围内均匀分布的随机数。
  - 输出 y ：设定真实函数为 $y = \sin(2\pi x)$ ，并加入均值为 0、标准差为 0.1 的高斯噪声 ϵ 。
- **步骤B：特征工程，构建设计矩阵 $\mathbf{\Phi}$**

  将输入向量 $\mathbf{x}$ 转换为包含各阶幂次的设计矩阵 $\mathbf{\Phi}$ 并验证 $\mathbf{\Phi}^T\mathbf{\Phi}$ 满秩。

  注：设计矩阵 $\mathbf{\Phi}$ 第一列为偏置项。
- **步骤C：模型求解与复杂度分析**
  - 解析解计算：对于给定的阶数 $M = [1, 3, 12]$ ，分别计算 $\hat{\mathbf{w}} = (\mathbf{\Phi}^T\mathbf{\Phi})^{-1}\mathbf{\Phi}^T\mathbf{y}$ 。
  - 可视化不同复杂度（阶数）下的数据与预测曲线，观察并分析。

四、 作业要求

- **代码：**整理出代码文件，规范添加注释。
- **报告：**依据本实验内容，形成实验报告。