机器学习上机实验07：线性回归-4

一、 实验题目

模型拟合的“度”以及损失函数的“偏见”

二、 实验目标

1. **定量关系理解**：通过实验观察并理解模型复杂度、正则化强度与偏差/方差之间的制约关系。
2. **泛化能力评估**：掌握通过测试集评估模型泛化能力的标准化流程，验证“泛化误差 = 偏差^2 + 方差 + 噪声”的核心理论。
3. **正则化机制直观感知**：观测正则化如何通过惩罚项抑制模型过拟合，并寻找最优的偏差-方差平衡点。
4. **最小二乘法局限性感知**：通过对比实验，直观观察离群点如何通过平方误差项“拉动”拟合曲线，导致决策边界偏移。

三、 实验环节与任务清单

1. 偏差与方差的定量分解 (Bias-Variance Trade-off)

任务 A：标准化数据环境搭建

- **全局随机种子设定**：统一使用种子 `42`，确保噪声生成与样本抽取可复现。
- **目标函数生成**：设定真实函数为 $y = \sin(2\pi x)$。在 [0, 1] 区间内取 100 个等间距点作为测试集（不含噪声）。

任务 B：“平行宇宙”多采样拟合

- **多数据集生成**：在训练样本中加入噪声 $\epsilon \sim \mathcal{N}(0, 0.15^2)$。循环生成 50 组不同的训练集，每组包含 20 个随机样本点。
- **岭回归批量拟合**：固定多项式阶数为 10。在 $\lambda \in [10^{-8}, 10^{-7}, 10^{-6}, 10^{-3}, 0.01, 0.1, 1, 10]$ 序列下进行线性回归拟合，并在测试集测试，记录 50×100 的预测矩阵。

任务 C：定量计算与可视化

- **统计量提取**：计算平均预测曲线、偏置平方 $Bias^2$、方差 Variance 及总误差（平方误差）Total Error。验证 $TotalError \approx Bias^2 + Variance$ 的一致性。
- **核心曲线绘制**：以 $\log_{10}(\lambda)$ 为横坐标，绘制偏差、方差、总误差的三色对比图。
- **极端参数对比**：选取 $\lambda = 10^{-8}$、$\lambda = 10$ 及最佳平衡点对应的 λ，分别绘制 50 条预测曲线（与对应的平均曲线）覆盖在真实正弦曲线上，观察震荡与偏离程度。

2. 线性回归在分类中的鲁棒性缺陷 (Robustness of OLS)

任务 A：基础数据与离群点构造

- **构建基础分布**：生成两类正态分布数据：类别 0（均值 2）、类别 1（均值 3），方差均为 0.5^2 。
- **引入极远距离离群点**：在 $x = 20$ 处添加一个标签为 1 的样本。观察该点在特征空间上的极端偏离。

任务 B：模型训练与决策边界追踪

- **回归模型拟合**：分别在基础数据集和含离群点数据集上训练线性回归模型 $h(x) = wx + b$ 。
- **决策边界定位**：设定分类阈值为 0.5，求解 $h(x) = 0.5$ 对应的边界位置 x_{db} 。

任务 C：偏移评价与“误伤”检测

- **边界偏移量计算**：观察加入离群点前后决策边界的位移。
- **样本误伤检查**：检查原本被正确分类的样本是否因边界移动被错误划分为类别 0。
- **平方误差权重分析**：思考为什么一个位置极远的“正确点”会导致模型牺牲中间区域的准确度。

一句话总结：我们追求的是一个鲁棒的系统，一个需要不断人工微调阈值才能工作的模型，在学术研究和工业落地中都被认为是不可靠的。

四、 作业要求

- **数据：**保留数据集，作为后续实验备用。
- **代码：**整理出代码文件，规范添加注释。
- **报告：**依据本实验内容，形成实验报告。
- **提交作业：**将之前上机课的数据集、代码、报告（自上次提交报告到本次，中间所有上机报告内容整合为一份pdf），打包后提交。提交截止日期为4月30日23点59分，提交方式后续在QQ群内通知。